

REDES NEURAIS CONVOLUCIONAIS



Introdução à CNN — Do pixel à classificação

AGENDA

01  Como o computador enxerga imagens

02  Etapa 1 — Convolução e filtros

03  Etapa 2 — Max Pooling

04  Etapa 3 — Flattening + Rede Densa

05  Funções de ativação e filtros comuns

06  Arquitetura completa e resumo

COMO O COMPUTADOR ENXERGA IMAGENS?


Uma imagem é apenas uma matriz de números

Escala de cinza (1 canal)

0	0	0	50	120	200	120	50	0	0
0	0	80	180	255	255	255	180	80	0
0	80	200	255	255	255	255	255	200	0
50	180	255	255	200	200	255	255	180	50
120	255	255	200	100	100	200	255	255	120
200	255	255	200	100	100	200	255	255	200
120	255	255	255	255	255	255	255	255	120
50	180	255	255	255	255	255	255	180	50
0	80	200	255	255	255	255	200	80	0
0	0	0	50	120	200	120	50	0	0



Colorida (3 canais RGB)



Pixel = número de 0 a 255

0 = preto (sem luz)

255 = branco (luz máxima)

Cinza: matriz $H \times W$

RGB: matriz $H \times W \times 3$

Fashion MNIST: imagens 28×28 em escala de cinza = 784 pixels = 784 features

O QUE É UMA CNN?



Rede Neural Convolucional

Uma arquitetura de deep learning especializada em processar dados com estrutura espacial (imagens, vídeo, áudio).

Diferente da MLP (rede densa), a CNN preserva a informação espacial — ela sabe que pixels vizinhos estão relacionados.

Preserva Espacialidade

Entende que pixels vizinhos formam padrões

Menos Parâmetros

Compartilha pesos via filtros reutilizáveis

Invariância à Translação

Reconhece objeto em qualquer posição

Hierarquia de Features

Bordas → Texturas → Partes
→ Objeto

AS 4 ETAPAS DE UMA CNN

1

CONVOLUÇÃO

Aplica filtros para extrair características (bordas, texturas, padrões)

2

MAX POOLING

Reduz a dimensionalidade mantendo as informações mais relevantes

3

FLATTENING

Transforma a matriz 2D em vetor 1D para alimentar a rede densa

4


REDE DENSA

Classificação final usando Softmax para gerar probabilidades

Imagem → Convolução → Pooling → Flatten → Dense → Classe

ETAPA 1 — CONVOLUÇÃO

O filtro (kernel) desliza sobre a imagem, multiplicando e somando valores



Campo Receptivo: região da imagem coberta pelo filtro em cada passo

Stride: quantos pixels o filtro avança a cada passo (padrão = 1)

FILTROS / KERNELS MAIS COMUNS

Cada filtro detecta um tipo diferente de padrão visual

Bordas Verticais

-1	0	1
-1	0	1
-1	0	1

Bordas Horizontais

-1	-1	-1
0	0	0
1	1	1

Laplaciano

0	-1	0
-1	4	-1
0	-1	0

Sharpen

0	-1	0
-1	5	-1
0	-1	0

Blur (Média)

1	1	1
1	1	1
1	1	1

Sobel X

-1	0	1
-2	0	2
-1	0	1

O que cada filtro detecta?

- Bordas Verticais: linhas de cima para baixo
- Bordas Horizontais: linhas da esquerda para direita
- Laplaciano: contornos e bordas em todas as direções
- Sharpen: aumenta contraste e nitidez
- Blur: suaviza a imagem (reduz ruído)
- Sobel: gradientes direcionais (intensidade)


Na CNN, os filtros são aprendidos automaticamente!



Na CNN, os filtros NÃO são definidos manualmente — são aprendidos automaticamente no treinamento!

ETAPA 2 — MAX POOLING

Seleciona o valor máximo de cada região, reduzindo a dimensão



Reduz dimensão

Menos parâmetros = treinamento mais rápido


Invariância

Reconhece padrões em posições diferentes

Anti-overfitting

Menos dados = menor risco de memorização

ETAPAS 3 E 4 — FLATTENING + REDE DENSA



Flattening


Transforma a matriz 2D (ou 3D com múltiplos filtros) em um vetor 1D. É a ponte entre as camadas convolucionais e a rede densa.

Rede Densa + Softmax

Camadas fully connected que processam as features extraídas. A última camada usa Softmax para gerar probabilidades (uma por classe).

FUNÇÕES DE ATIVAÇÃO MAIS COMUNS


Introduzem não-linearidade na rede — sem elas, a CNN seria apenas uma multiplicação de matrizes



Função	Onde é usada	Range
ReLU	Camadas ocultas (conv + dense)	$[0, +\infty)$
Sigmoid	Saída binária (sim/não)	$[0, 1]$
Softmax	Última camada — multiclasse	$[0, 1]$ (soma=1)

ARQUITETURA COMPLETA DA CNN

Fashion MNIST — Classificação de 10 categorias de roupas



Fluxo de dimensões:

$(28, 28, 1) \rightarrow \text{Conv} \rightarrow (26, 26, 32) \rightarrow \text{Pool} \rightarrow (13, 13, 32) \rightarrow \text{Conv} \rightarrow (11, 11, 64) \rightarrow \text{Pool} \rightarrow (5, 5, 64) \rightarrow \text{Flatten} \rightarrow (1600) \rightarrow \text{Dense} \rightarrow (128) \rightarrow \text{Dense} \rightarrow (10)$

O QUE A CNN APRENDE EM CADA CAMADA?

Camadas Iniciais

Detectam padrões simples:
bordas, linhas, gradientes



Camadas Intermediárias

Combinam padrões simples
em texturas e formas



Camadas Profundas

Reconhecem partes de
objetos e objetos inteiros



Esse aprendizado hierárquico é o que torna as CNNs tão poderosas para visão computacional!

CNN vs MLP — POR QUE CNN É MELHOR PARA IMAGENS?

Aspecto	MLP (Rede Densa)	CNN (Convolutacional)
Entrada	Vetor 1D (784 valores)	Matriz 2D (28×28×1)
Info Espacial	❌ Perdida no flatten	✅ Preservada
Parâmetros	Muitos (todos conectados)	Poucos (filtros compartilhados)
Invariância	❌ Sensível à posição	✅ Invariante (pooling)
Acurácia típica*	~87-88%	~91-92%

**Valores aproximados no Fashion MNIST com 10 épocas de treino*



Para imagens, a CNN é sempre a melhor escolha — ela foi projetada para preservar e explorar a estrutura espacial dos dados.

RESUMO DA AULA



Imagens são matrizes numéricas — cada pixel é um número de 0 a 255



A convolução aplica filtros que extraem características (bordas, texturas, padrões)



O Max Pooling reduz dimensionalidade e gera invariância à translação



Flattening + Rede Densa fazem a classificação final com Softmax



ReLU é a ativação padrão em camadas ocultas; Softmax na saída multiclasse



Os filtros são aprendidos — a CNN descobre sozinha o que importa

Próximos passos: Data Augmentation, Transfer Learning, CNN com imagens coloridas (RGB)

PRÁTICA!

Implementando uma CNN com TensorFlow/Keras



Notebook: `CNN_Introducao_Fashion_MNIST.ipynb`

Dataset: Fashion MNIST (28×28, escala de cinza, 10 classes)

Frameworks: TensorFlow, Keras, NumPy, Matplotlib

OBRIGADO!

FIAP — MBA em Data Science

Redes Neurais Convolucionais — Introdução